

Libro de códigos

Metadatos del conjunto

- **Fuente:** Buscador de establecimientos educativos del MINEDUC (https://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/).
- **Fecha de extracción:** 2026-07-18.
- **Filtro:** NIVEL ESCOLAR = DIVERSIFICADO.
- **Cobertura:** los 22 departamentos; el buscador consultó CIUDAD CAPITAL como entidad separada de GUATEMALA.
- **Versión final:** v1.0.0.
- **CSV crudo:** data/raw/establecimientos_raw.csv, 11,891 filas y 17 variables.
- **SHA-256 crudo:** bbc1fa3b26b2509a22d547dc81dfa3b8bbc470f33c26b210de5b448d8d1a1d1c.
- **CSV limpio candidato:** data/processed/establecimientos_limpio_candidato.csv, 11,868 filas y 18 variables.
- **SHA-256 del candidato:** a337c8761a3d4636b4ba2f4584d91d4f9525c0ab2f145c96d4cb7a965168ff97.
- **CSV limpio final:** data/processed/establecimientos_clean.csv, 11,868 filas y 18 variables, ordenadas establemente por CODIGO.
- **SHA-256 final:** 429468cb07a6e31aeb2a1d27611b0d82952a5c909f2b6a454fc03b12a1ec5b49.
- **Discrepancia de referencia:** el hash 0364f39e... incluido en la planificación no corresponde a los bytes del candidato presente. La huella real del candidato se recalculó arriba; el hash final se calcula después de ordenar y escribir el archivo final.
- **Catálogo geográfico:** Instituto Nacional de Estadística (INE), 22 departamentos y 340 municipios; implementado y citado en src/catalogos.py.

Diccionario de variables

La columna “Valores posibles” describe el conjunto final. NA significa que la fuente no proporcionó un valor válido; no representa texto literal. En todos los campos, “MINEDUC” se refiere al Buscador de establecimientos educativos indicado en los metadatos.

CODIGO

Descripción: Identificador oficial del establecimiento asignado por MINEDUC.

Tipo de dato: Texto (string)

Dominio permitido: Patrón NN-NN-NNNN-NN; no nulo; único.

Valores posibles: 11,868 códigos únicos.

Tratamiento aplicado: Se conservaron ceros y guiones; se validó el patrón. Las 23 ausencias pertenecían a filas estructurales eliminadas.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

DISTRITO

Descripción: Código del distrito educativo.

Tipo de dato: Texto (string)

Dominio permitido: NN-NNN, NN-NN-NNNN o NA.

Valores posibles: 1,678 códigos válidos observados; 603 registros NA.

Tratamiento aplicado: Se conservaron los dos formatos completos usados por la fuente; 70 valores incompletos como 01- pasaron a NA.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

DEPARTAMENTO

Descripción: Departamento oficial donde se ubica el establecimiento.

Tipo de dato: Texto categórico (string)

Dominio permitido: Los 22 departamentos definidos en src/catalogos.py; no nulo.

Valores posibles: 22 departamentos.

Tratamiento aplicado: Se normalizó escritura y CIUDAD CAPITAL se convirtió a GUATEMALA en 2,161 registros.

Variables derivadas: Origina ZONA_CAPITAL junto con MUNICIPIO.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC + catálogo INE

Versión del conjunto limpio: v1.0.0

MUNICIPIO

Descripción: Municipio oficial correspondiente al departamento.

Tipo de dato: Texto categórico (string)

Dominio permitido: Uno de los 340 municipios y perteneciente al departamento de la fila; no nulo.

Valores posibles: 330 municipios presentes, validados contra src/catalogos.py.

Tratamiento aplicado: Las zonas capitalinas se asignaron al municipio GUATEMALA; se aplicaron 15 equivalencias documentadas de nombres históricos, extendidos o erróneos.

Variables derivadas: Origina ZONA_CAPITAL cuando la consulta original fue CIUDAD CAPITAL.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC + catálogo INE

Versión del conjunto limpio: v1.0.0

ZONA_CAPITAL

Descripción: Zona reportada por el buscador para establecimientos de Ciudad de Guatemala.

Tipo de dato: Texto categórico (string)

Dominio permitido: ZONA 1 a ZONA 25 cuando fue informada, o NA.

Valores posibles: 22 zonas observadas; 2,161 registros informados y 9,707 NA.

Tratamiento aplicado: Se derivó antes de convertir departamento y municipio a GUATEMALA; no se infirió desde direcciones.

Variables derivadas: Variable derivada de DEPARTAMENTO y MUNICIPIO originales.

Fecha de extracción: 2026-07-18

Fuente: Derivada de MINEDUC

Versión del conjunto limpio: v1.0.0

ESTABLECIMIENTO

Descripción: Nombre del centro educativo.

Tipo de dato: Texto (string)

Dominio permitido: Texto normalizado o NA.

Valores posibles: 6,312 valores no nulos observados; 5 registros NA.

Tratamiento aplicado: Se unificaron Unicode, mayúsculas y espacios; se conservaron tildes y palabras. No se corrigieron nombres por similitud.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

DIRECCION

Descripción: Dirección física informada por el establecimiento.

Tipo de dato: Texto (string)

Dominio permitido: Texto normalizado o NA.

Valores posibles: 7,431 valores distintos no nulos; 89 registros NA.

Tratamiento aplicado: Los valores formados solo por puntuación pasaron a NA; se normalizaron Unicode, mayúsculas y espacios sin geocodificar.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

TELEFONO

Descripción: Uno o más teléfonos de contacto.

Tipo de dato: Texto (string)

Dominio permitido: Cada número cumple [2-7]NNNNNN; múltiples números se separan con / ; puede ser NA.

Valores posibles: 1 o más números de 8 dígitos; 1,063 registros NA.

Tratamiento aplicado: Se extrajeron solo números completos, se eliminaron repeticiones dentro de la celda y no se infirieron dígitos faltantes.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

SUPERVISOR

Descripción: Nombre del supervisor educativo informado.

Tipo de dato: Texto (string)

Dominio permitido: Texto normalizado o NA.

Valores posibles: 1,279 valores distintos no nulos; 539 registros NA.

Tratamiento aplicado: Los valores sin caracteres alfanuméricos pasaron a NA; se normalizaron Unicode, mayúsculas y espacios, conservando las tildes.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

DIRECTOR

Descripción: Nombre del director informado.

Tipo de dato: Texto (string)

Dominio permitido: Texto normalizado o NA.

Valores posibles: 5,489 valores distintos no nulos; 2,142 registros NA.

Tratamiento aplicado: SIN DATO y valores formados solo por puntuación se convirtieron a NA; se retiró un prefijo decorativo de guiones sin modificar el nombre.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

NIVEL

Descripción: Nivel escolar de la consulta.

Tipo de dato: Texto categórico (string)

Dominio permitido: DIVERSIFICADO; no nulo.

Valores posibles: DIVERSIFICADO.

Tratamiento aplicado: Se verificó el filtro después de eliminar las filas vacías.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

SECTOR

Descripción: Sector administrativo del establecimiento.

Tipo de dato: Texto categórico (string)

Dominio permitido: OFICIAL, PRIVADO, COOPERATIVA, MUNICIPAL; no nulo.

Valores posibles: 4 categorías.

Tratamiento aplicado: Se normalizaron Unicode, mayúsculas y espacios; no fue necesario unificar categorías.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

AREA

Descripción: Área geográfica declarada por la fuente.

Tipo de dato: Texto categórico (string)

Dominio permitido: URBANA, RURAL, SIN ESPECIFICAR; no nulo.

Valores posibles: 3 categorías.

Tratamiento aplicado: Se conservó SIN ESPECIFICAR como categoría explícita, no como faltante.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

STATUS

Descripción: Estado operativo del establecimiento.

Tipo de dato: Texto categórico (string)

Dominio permitido: ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE, TEMPORAL TITULOS, TEMPORAL NOMBRAMIENTO; no nulo.

Valores posibles: 5 categorías.

Tratamiento aplicado: Se normalizó el formato y se conservaron todos los estados semánticamente distintos.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

MODALIDAD

Descripción: Modalidad lingüística del establecimiento.

Tipo de dato: Texto categórico (string)

Dominio permitido: MONOLINGUE, BILINGUE; no nulo.

Valores posibles: 2 categorías.

Tratamiento aplicado: Se normalizó a mayúsculas sin tildes para evitar variantes de escritura.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

JORNADA

Descripción: Jornada en la que opera el registro educativo.

Tipo de dato: Texto categórico (string)

Dominio permitido: MATUTINA, VESPERTINA, NOCTURNA, DOBLE, INTERMEDIA, SIN JORNADA; no nulo.

Valores posibles: 6 categorías.

Tratamiento aplicado: Se conservó SIN JORNADA como categoría declarada, no como faltante.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

PLAN

Descripción: Plan o modalidad temporal de estudios.

Tipo de dato: Texto categórico (string)

Dominio permitido: Las 13 categorías observadas y documentadas; no nulo.

Valores posibles: DIARIO(REGULAR), FIN DE SEMANA, cuatro modalidades semipresenciales diferenciadas y otras siete categorías.

Tratamiento aplicado: Se normalizaron 505 valores con tildes; no se fusionaron las modalidades semipresenciales porque expresan frecuencias distintas.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

DEPARTAMENTAL

Descripción: Dirección Departamental de Educación responsable; puede ser una subregión.

Tipo de dato: Texto categórico (string)

Dominio permitido: 26 valores observados, incluidos GUATEMALA NORTE/SUR/ORIENTE/OCCIDENTE y QUICHE NORTE; no nulo.

Valores posibles: 26 categorías.

Tratamiento aplicado: Se normalizaron 2,026 valores con tildes. Se validó igualdad con el departamento o prefijo administrativo permitido, sin eliminar subregiones.

Variables derivadas: No aplica.

Fecha de extracción: 2026-07-18

Fuente: MINEDUC

Versión del conjunto limpio: v1.0.0

Reglas de identidad y duplicados

- CODIGO es la clave de la unidad registral y es único en el conjunto final.
- Dos filas con nombre, dirección o teléfono similares no se fusionan si poseen códigos MINEDUC diferentes sin confirmación explícita de la fuente.
- Los 781 pares candidatos quedaron documentados individualmente en `data/processed/duplicados_revisados.csv`; todos se conservaron en esta versión.
- Las 23 filas completamente vacías del CSV crudo se eliminaron porque eran separadores sin establecimiento asociado.

Anexo de reglas de validación

Las reglas se ejecutan desde `src/validadores.py` y se verifican con `pytest`, `05_validacion.ipynb` y `06_dataset_final.ipynb`. El conjunto final supera las siete comprobaciones con cero errores.

Variable	Tipo esperado	Nulabilidad	Regla automática principal
CODIGO	string	No permite NA	Patrón NN-NN-NNNN-NN, valor único y sin duplicados.
DISTRITO	string	Permite NA	Patrón NN-NNN o NN-NN-NNNN cuando está informado.
DEPARTAMENTO	string	No permite NA	Pertenece al catálogo de 22 departamentos.
MUNICIPIO	string	No permite NA	Pertenece al catálogo de 340 municipios y al departamento de la fila.
ZONA_CAPITAL	string	Permite NA	Patrón ZONA 1 a ZONA 25; si existe, departamento y municipio deben ser GUATEMALA.
ESTABLECIMIENTO	string	Permite NA	Sin espacios extremos/múltiples, centinelas literales ni puntuación residual.
DIRECCION	string	Permite NA	Sin espacios extremos/múltiples, centinelas literales ni puntuación residual.
TELEFONO	string	Permite NA	Uno o más números de ocho dígitos iniciados entre 2 y 7, separados por / .
SUPERVISOR	string	Permite NA	Sin espacios extremos/múltiples, centinelas literales ni puntuación residual.
DIRECTOR	string	Permite NA	Sin espacios extremos/múltiples, centinelas literales ni puntuación residual.
NIVEL	string	No permite NA	Únicamente DIVERSIFICADO.
SECTOR	string	No permite NA	Una de las cuatro categorías documentadas.
AREA	string	No permite NA	URBANA, RURAL o SIN ESPECIFICAR.
STATUS	string	No permite NA	Uno de los cinco estados documentados.
MODALIDAD	string	No permite NA	MONOLINGUE o BILINGUE.

Variable	Tipo esperado	Nulabilidad	Regla automática principal
JORNADA	string	No permite NA	Una de las seis jornadas documentadas.
PLAN	string	No permite NA	Una de las trece categorías documentadas, sin fusionar frecuencias semipresenciales.
DEPARTAMENTAL	string	No permite NA	Una de las 26 direcciones permitidas y consistente con DEPARTAMENTO.

Además del esquema por variable, la suite comprueba duplicados exactos y categorías equivalentes que solo difieran en mayúsculas, tildes, espacios o puntuación. Cada fallo reporta hasta cinco ejemplos con índice, código, variable, valor y regla incumplida.

Historial de contribuciones verificable

La atribución se limita a evidencia del historial Git y al estado actual del árbol; no se infieren autores para trabajo sin commit.

- **Persona A — JosFer720:** estructura, entorno, obtención, diagnóstico inicial y metadatos del dataset, según los commits 1a626aa, f6df659, faaa03c y 8053846.
- **Persona B — Joel Jaquez:** planificación, pipeline de limpieza, candidato, trazabilidad de transformaciones/duplicados y automatización inicial de notebooks, según los commits entre dfdf0e2 y 99b8711.
- **Persona C — Jose Galindo (Home):** correcciones residuales, validaciones automáticas e informe reproducible Antes/Después, según 51c1dd2, dfad986 y 05c0333.
- **Persona D:** trabajo actual aún no atribuido por commit: esquema y exportador final, pruebas de entrega, edición final de este libro, PDF, 06_dataset_final.ipynb, CSV v1.0.0 y actualización final del README. No se inventa un nombre personal para esta contribución.